



بخش اول

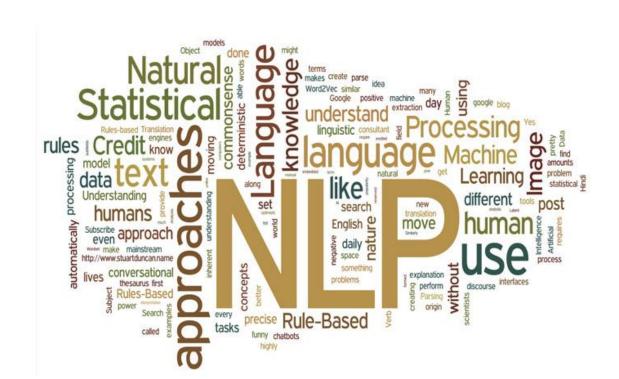
مقدمات پردازش زبان طبیعی

حميدرضا برادران كاشاني



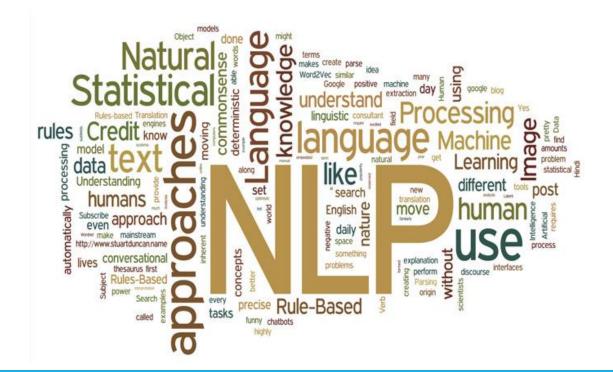
اهداف این بخش:

- ❖ پردازش زبان طبیعی (NLP) چیست؟
 - ❖ کاربردهای NLP چیست؟
 - ❖ چرا NLP سخت است؟





پردازش زبان طبیعی چیست؟





تعریف NLP

♦ زبان طبیعی زبانی است که در تعاملات اجتماعی روزمره با استفاده از آن مینویسیم و صحبت میکنیم.

- به بیان ساده منظور از زبان طبیعی، زبان انسانی است.
- پردازش زبان طبیعی (NLP) یکی از شاخههای علوم کامپیوتر و هوش مصنوعی است که به تعاملات بین کامپیوتر و انسان، از طریق زبان طبیعی میپردازد.
 - به تعریف دقیقتر، پردازش زبانهای طبیعی عبارت است از استفاده از کامپیوتر برای پردازش: زبان گفتاری و زبان نوشتاری.
- بدین معنی که کامپیوترها را قادر سازیم که گفتار یا نوشتار تولید شده در قالب و ساختار یک زبان طبیعی را تحلیل و **درک** نموده یا آن را **تولید** نمایند.



تعریف NLP

- به عبارتی در زبان طبیعی بایستی کامپیوترها یاد بگیرند:
- $ext{$^\circ$}$ چگونه می توان زبان را **درک** کرد (Language $\underline{ extsf{U}}$ nderstanding)
 - $ext{*}$ چکونه می توان زبان را **تولید** کرد (Language <u>G</u>eneration)؟





ارتباطات و زبان (Language and Communication)

Speaker

- Intention (goals, shared knowledge and beliefs)
- Generation (tactical)
- Synthesis (text or speech)

Listener

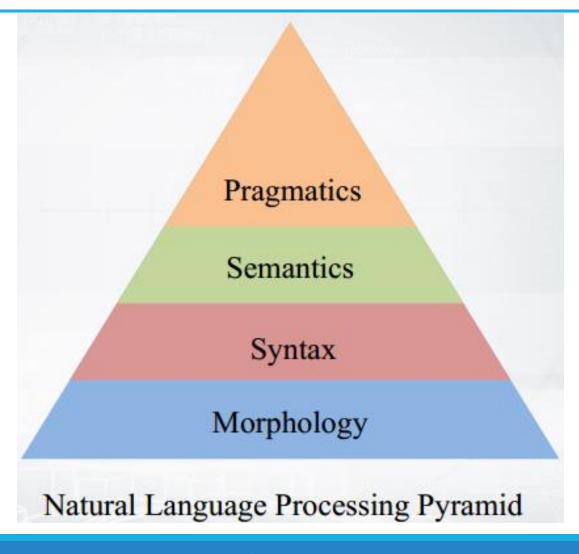
- Perception
- Interpretation (syntactic, semantic, pragmatic)
- Incorporation (internalization, understanding)

Both

Context (grounding)

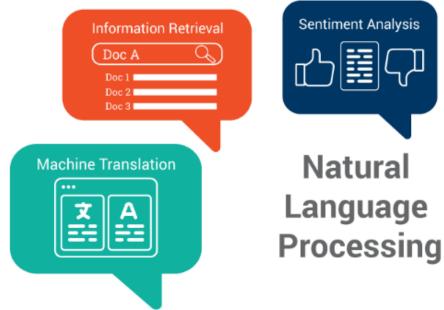


NLP Pyramid





کاربردهای پردازش زبان طبیعی؟









💠 فرض کنید می خواهیم بدانیم نقل قول زیر از کجا آمده است؟

Dave Bowman: Open the pod bay doors, HAL.

HAL: I'm sorry Dave. I'm afraid I can't do that.

این نقل قول مربوط به یک فیلم با عنوان 2001:Space Odyssey ساخته Stanley در ۱۹۶۸ است. Kubrick

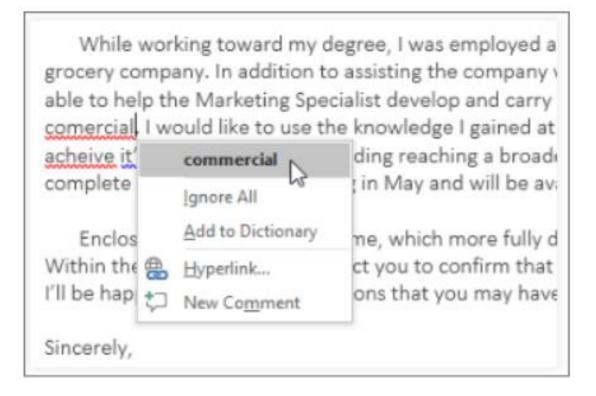


این فیلم یکی از اولین داستان های علمی است که در آن کامپیوترها با انسان به زبان طبیعی تعامل می کنند.



💠 تصحیح خطاهای املایی (Spell Correction)







(Information Extraction) استخراج اطلاعات

Subject: curriculum meeting

Date: January 15, 2012

To: Dan Jurafsky

Hi Dan, we've now scheduled the curriculum meeting.

It will be in Gates 159 tomorrow from 10:00-11:30.

-Chris

Create new Calendar entry



Event: Curriculum mtg

Date: Jan-16-2012

Start: 10:00am

End: 11:30am

Where: Gates 159



NLP کاربردهای

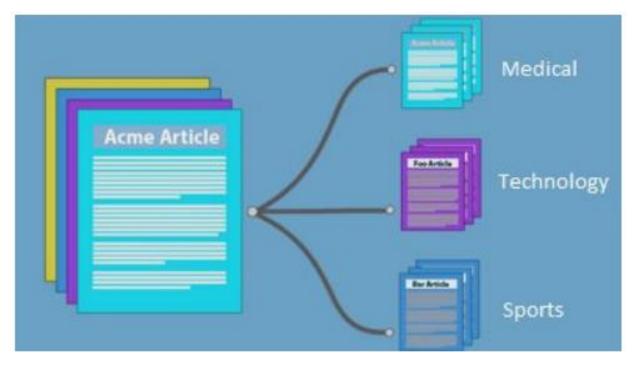






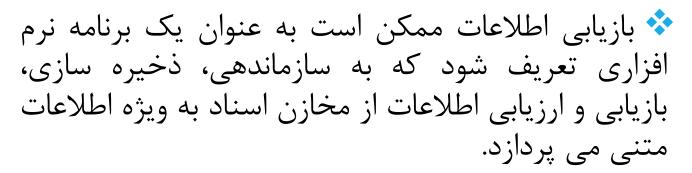
(Text Classification) دسته بندی متون





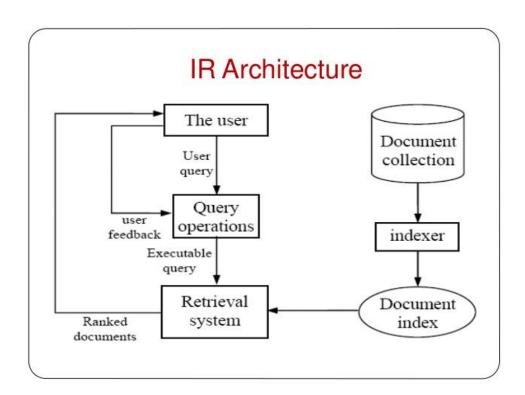


💠 بازیابی اطلاعات (Information Retrieval)



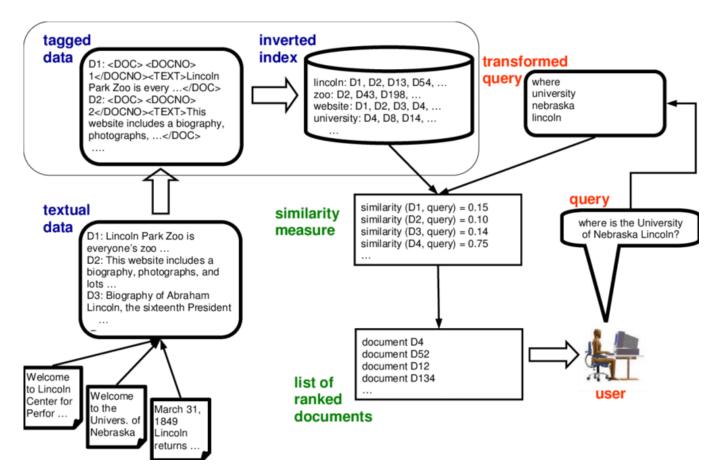
این سیستم به کاربران در یافتن اطلاعات مورد نیاز کمک می کند اما به صراحت جواب سوالات را بر نمی گرداند.

اسنادی که نیاز کاربر را برآورده کند، اسناد مرتبط (relevant documents) نامیده می شوند.





💠 بازیابی اطلاعات (Information Retrieval) – ادامه





💠 خلاصه سازی متون (Text Summarization)



GOLD

Gas mileage is below what is expected. Gas mileage is below what is expected. Gas mileage is good once car is broken in.

The gas mileage on the camry was not good as it was advertised to be.

This car looks great and the build quality is good. Mine suffers from the tranny slip on the 3, 4 upshift when cold, build quality is good but nothing like the Toyota, hype I was expecting, as it has its share of squeaks and rattles just like a 10 year old Chevy. Overall a good car, no build quality issues yet. This was the 7th Camry and the last, I feel Toyota quality is slipping big time.

EXTRACTIVE

ABSTRACTIVE

The gas mileage is still good. Cant give specifcs but for v6, its good. Being a mother who drives a lot i wanted a safe vehicle with good gas mileage. The interior is roomy, the ride is smooth and solid and yet it has excellent gas mileage. The corolla is the best toyota car when it comes to gas per mileage



كاربردهاي NLP

💠 موتورهای جستجو (Search Engines)

- 🍫 مانند Yahoo ،Google و Bing یا موتورهای جستجو مشهور در زبانهای دیگر مثل Baidu در چینی
- بهره می برند بطوریکه سعی کرده تا موردهای جستجو و سوالات ightharpoonup NLP بهره می برند بطوریکه سعی کرده تا موردهای جستجو و سوالات کاربر (queries) را درک کرده (understanding) و سندهای تطبیق یافته با آن مورد را برای کاربر پیابند.





(Question Answering: QA) پاسخ سوالات

💠 برنده یک مسابقه تلویزیونی در ۱۶ فوریه ۲۰۱۱: سیستم مشهور IBM's watson





كاربردهاي NLP

(Web-based Question Answering) پاسخ سوالات مبتنی بر وب

یک تعمیم از جستجوی وب ساده است که در آن کاربر به جای آن که فقط کلمات کلیدی (keywords) را تایپ کند، می تواند سوالات کاملی را از سوالات ساده تا سخت مطرح کند، مثلا؟ "what does "divergent" mean?"

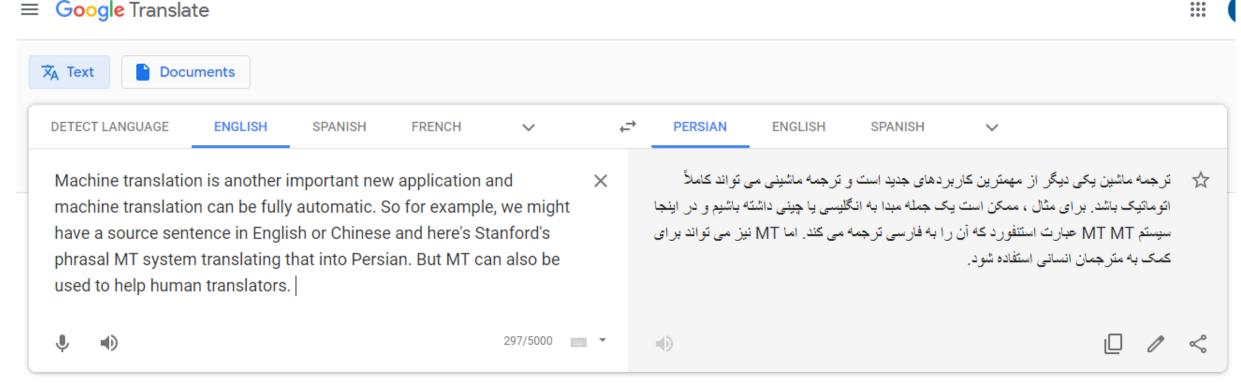
"What year was Abraham Lincoln born?"

How much Chinese silk was exported to Western Europe by the end of the 18th century? «دانشگاه های مختلف ایران در چه حوزه هایی از پردازش زبان طبیعی تحقیقات بیشتری داشته اند؟»

❖ برای سوالاتی که حالت تعریف (definition questions) داشته یا تنها برخی فاکتورها مثل زمان یا مکان یک رخداد را اشاره دارد، معمولا همان موتور جستجو پاسخ کاربر را می دهد. اما برای سوالات پیچیده که معمولا نیاز به یک سری استنتاج ها بر اساس تعدادی واقعیت (facts) دارد، قطعا روش های پردازش زبان طبیعی پیچیده تری نیاز است.



💸 ترجمه ماشینی (Machine Translation)



Send feedback



💠 سیستم های گفتگو (Dialog Systems)

User: I need a flight from Tehran to Isfahan, arriving by 9 pm?

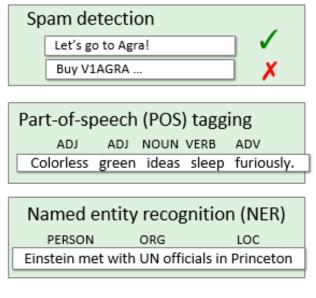
System: What day are you flying on?

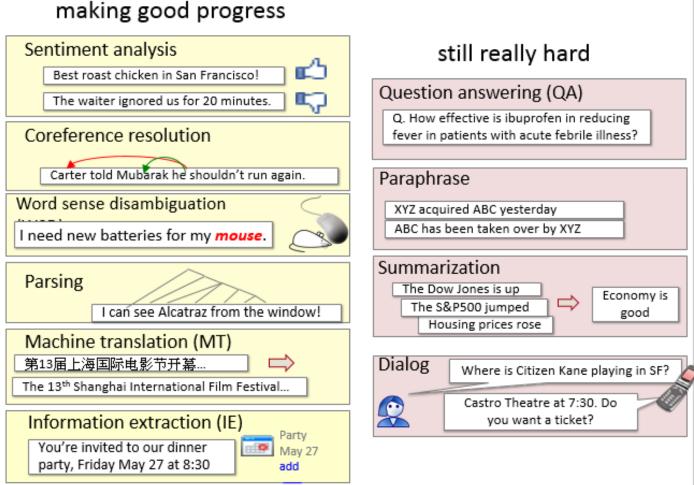
User: Tomorrow

System: Returns a list of flights

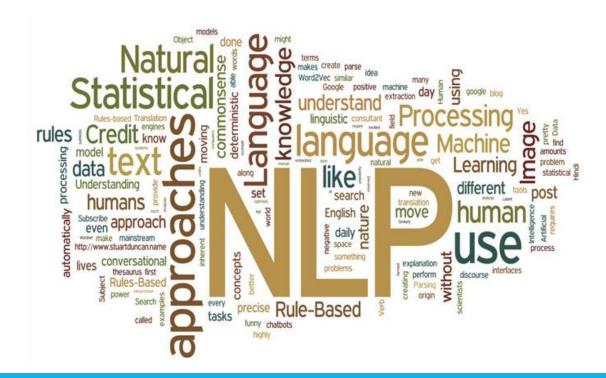


mostly solved









Hamidreza Baradaran Kashani



- ان، عدم رعایت قواعد گرامری توسط افراد مختلف یک زبان،
 - انعطاف پذیری گرامری بالا در زبان های مختلف،
 - استفاده افراد از علائم نقطه گذاری در جملات،
- 💠 مثلا جمله زیر را در نظر بگیرید که معانی مختلفی از آن برداشت می شود (گرامر آن کاملا صحیح است):

"At last a computer that understands you like your mother"

- 1. It understands you as well as your mother understands you
 - 2. It understands that you like your mother
 - 3. It understands you as well as it understands your mother

Hamidreza Baradaran Kashani



- * ابهام (ambiguity) در سطوح مختلفی ممکن است حاصل شود:
 - ❖ ابهام در سطح آکوستیکی (acoustic level)
- مثلا یک سیستم بازشناسی گفتار (Speech Recognizer) ممکن است با شنیدن جمله فوق
 دو نتیجه زیر را گزارش دهد:
 - 1. ... a computer that understand you like your mother
 - 2. ... a computer that understand you lie cured mother

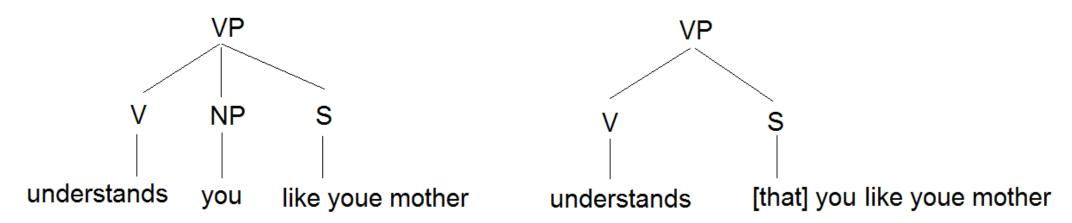
❖ هر دو عبارت like your و like دو دنباله دو کلمه ای معتبر از لحاظ گرامری در زبان انگلیسی هستند، با این حال بواسطه شباهت تلفظ آکوستیکی دو دنباله ممکن است سیستم بازشناسی در تشخیص متن صحیح دچار مشکل شود، اگرچه با استفاده از مدلهای زبانی (علاوه بر مدل آکوستیکی) احتمال بالاتری به عبارت اول داده می شود.

Hamidreza Baradaran Kashani



پهام در سطح نحوی (syntactic level)

○ ممکن است یک الگوریتم تجزیه گر نحوی (syntactic parser) دو تجزیه مختلف را برای یک جمله حاصل کند.

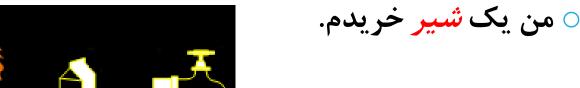


○ ساختارهای نحوی مختلف منجر به تعبیرهای مختلفی هم خواهد شد.



ابهام در سطح معنایی (semantic level)

- این ابهام را می توان نمونه ای از ابهام معنی (حس) کلمه (word sense ambiguity) در نظر گرفت.
- در واقع در دیکشنری هر زبان کلمات زیادی وجود دارند که برای آنها چند معنی بیان شده است، بسته به آنکه آن کلمه در چه متنی یا دنباله ای از کلمات مجاورش (context) بکار رفته است.
 - برای مثال ابهام در معنی کلمه شیر در جمله:



Hamidreza Baradaran Kashani



🛠 ابهام در سطح گفتمان یا چند بند (discourse level or multi-clause)

- یک گفتمان در حالت کلی از چند جمله می تواند تشکیل شود.
- در جملات مختلف و پیوسته معمولا ضمایری استفاده می شود که به برخی از موجودیت ها در در جملات قبل مرتبط می شود. این مساله، یافتن مرجع ضمایر یا resolution نامیده می شود.

برای مثال:

على به مغازه پدرش رفت. أو معمولا دوشنبه ها به آنجا مي رود.

Hamidreza Baradaran Kashani



مهارت های مورد نیاز

اشنایی با موارد زیر:

- جبر خطی (بردارها، ماتریس ها و عملیات روی آن ها)
 - تئوري احتمالات پایه
 - ر برنامه نویسی بویژه پایتون
 - آشنایی با مفاهیم یادگیری ماشین